

ПЕТРОЗАВОДСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИНСТИТУТ МАТЕМАТИКИ И ИНФОРМАЦИОННЫХ ТЕХНОЛОГИЙ
КАФЕДРА ИНФОРМАТИКИ И МАТЕМАТИЧЕСКОГО
ОБЕСПЕЧЕНИЯ

01.04.02 - Прикладная математика и информатика
Интеллектуальные интернет-технологии

Отчет о практике по научно-исследовательской работе
Модели компьютерного зрения в производственных веб-системах
(промежуточный)

Выполнил:

студент 5 курса группы 22503

О. А. Плугин _____
подпись

Место прохождения практики:

Кафедра информатики и математического обеспечения

Период прохождения практики:

01.09.25-28.12.25

Руководитель:

Д. Ж. Корзун, к. ф-м. н., доцент

подпись

Итоговая оценка

оценка

Петрозаводск — 2025

Содержание

Введение	3
1 Методы повышения точности и производительности малых моделей детекции объектов	6
1.1 Постановка задачи	6
1.2 Параметры и метрики задачи	7
1.3 Формулировка задачи оптимизации	8
1.4 Алгоритм повышения точности сети	10
1.5 Итоги анализа	13
2 Система видеоаналитики дефектов дорожного покрытия	16
2.1 Цели и задачи системы	16
2.2 Источники данных	17
2.3 Методы и подходы	17
Заключение	19
Список литературы	21

Введение

В условиях активного развития технологий и внедрения подходов искусственного интеллекта в прикладные задачи всё большую актуальность приобретают системы автоматизированного анализа визуальных данных. Компьютерное зрение находит широкое применение в промышленности, транспортной инфраструктуре и системах мониторинга, где требуется обработка больших объёмов видеоданных в режиме, близком к реальному времени. Особое значение при этом приобретают вопросы точности, производительности и адаптации алгоритмов машинного обучения к реальным условиям эксплуатации.

Одной из ключевых проблем при внедрении систем видеоаналитики является ограниченность вычислительных ресурсов, на которых требуется выполнять обработку видеоданных. Во многих прикладных задачах модели нейросетей должны функционировать на низкопроизводительных или мобильных устройствах, что накладывает ограничения на размер модели, время обработки одного кадра и общее потребление вычислительных ресурсов. В связи с этим актуальной является задача оптимизации моделей нейросетей компьютерного зрения с целью обеспечения возможности их применения в условиях ограниченных аппаратных ресурсов без существенной потери точности распознавания.

Второй важной практической задачей является автоматизация анализа видеоданных в предметных областях, где традиционно используется ручная или экспертная оценка. К таким за-

дачам относится мониторинг состояния дорожной инфраструктуры, в частности автоматическое обнаружение и классификация дефектов дорожного покрытия по изображениям и видео. Использование методов компьютерного зрения в данной области позволяет повысить объективность оценки состояния дорог и сократить трудоёмкость обследований. Современные подходы к детекции объектов в режиме реального времени основаны на архитектурах YOLO, SSD и их модификациях [2, 3].

Таким образом, в рамках магистерской работы рассматриваются две взаимосвязанные практические задачи:

- обеспечение возможности работы обученных моделей нейросетей компьютерного зрения на низкопроизводительных устройствах за счёт применения и анализа алгоритмов оптимизации;
- применение методов компьютерного зрения для автоматического распознавания дефектов дорожного покрытия по видеоданным.

Целью данной магистерской работы является анализ предметной области и современных подходов к применению и оптимизации методов компьютерного зрения для задач видеоаналитики, а также формирование теоретического и методического задела для дальнейших исследований в данной области.

Параллельно с теоретическим анализом ведётся работа над практическим проектом в области видеоаналитики дорожной инфраструктуры. Проект ориентирован на исследование подходов к автоматическому обнаружению и классификации дефек-

тов дорожного покрытия на основе видеоданных, получаемых с мобильной лаборатории, оснащённой видеокамерами и дополнительными измерительными датчиками. Особое внимание при этом уделяется вопросам применимости и эффективности моделей нейросетей в реальных условиях эксплуатации.

Для достижения поставленной цели в рамках текущего этапа магистерской работы необходимо решить следующие взаимосвязанные задачи:

1. Изучение и анализ научных подходов к оптимизации моделей нейросетей компьютерного зрения с точки зрения повышения производительности и снижения вычислительных затрат.
2. Анализ практической задачи видеоаналитики дефектов дорожного покрытия, включая используемые данные, методы распознавания и требования к вычислительной эффективности моделей.
3. Формирование выводов и определение направлений дальнейших исследований в рамках магистерской диссертации.

Данный промежуточный отчёт имеет следующую структуру.

В **первом разделе** представлен анализ научной статьи, посвящённой методам оптимизации моделей нейросетей для задач компьютерного зрения.

Во **втором разделе** приводится описание проекта системы видеоаналитики дефектов дорожного покрытия и анализ применяемых подходов.

1 Методы повышения точности и производительности малых моделей детекции объектов

1.1 Постановка задачи

В анализируемой научной статье рассматривается прикладная задача повышения эффективности модели нейросетей детекции объектов, предназначенной для обработки видеопотока в режиме реального времени на устройствах с ограниченными вычислительными ресурсами.

Основная практическая проблема заключается в том, что современные модели распознавания объектов обладают высокой точностью, но требуют значительных вычислительных ресурсов, что делает их непригодными для использования на мобильных и встраиваемых устройствах. В то же время упрощение архитектуры модели приводит к заметному снижению качества распознавания.

В качестве исходных ограничений рассматриваются процессор с 4 ядрами частотой 2,2 ГГц, оперативная память до 4 ГБ и обработка изображений с разрешением до 1920×1080 пикселей. При таких условиях использование крупных моделей нейросетей становится невозможным. Это показывает необходимость адаптации модели под реальные условия эксплуатации, и изменения включают в себя:

- уменьшение числа слоёв и их глубины;

- изменения параметров входных параметров;

Таким образом, задача статьи формулируется как поиск баланса между точностью распознавания и производительностью модели, позволяющего использовать алгоритмы компьютерного зрения в реальных системах с ограниченными вычислительными ресурсами.

В рамках данной главы методы повышения точности и производительности малых моделей детекции объектов рассматриваются на примере научной статьи [1], в которой предложен алгоритм оптимизации параметров модели нейросетей для работы в условиях ограниченных вычислительных ресурсов.

1.2 Параметры и метрики задачи

В задаче оптимизации модели нейросетей рассматриваются следующие ключевые параметры:

- **Архитектура сети:** количество слоёв n , шаг карты признаков $feat_{st}$ и количество фильтров f . Эти параметры влияют на точность распознавания mAP и скорость работы модели FPS .
- **Входные данные:** размер входного изображения $W \times H$ ($W = H$). Любое изображение автоматически преобразуется к заданному размеру. Увеличение разрешения повышает точность, но снижает производительность.
- **Якоря (anchors):** количество рамок k и их размеры w_a, h_a , которые определяют качество локализации объектов (IoU).

Метрики оценки

Основные показатели качества и производительности модели:

- mAP (mean Average Precision, % 0-1) — среднее значение точности по всем классам и порогам IoU;
- $Precision$ (доля корректно найденных объектов, % / 0-1);
- $Recall$ (доля реальных объектов, найденных моделью, % / 0-1);
- IoU (Intersection over Union, 0-1) — точность совпадения предсказанной области с истинной;
- FPS (frames per second, кадры/сек) — количество обрабатываемых кадров в секунду;
- T_1 (мс) — время обработки одного кадра.

1.3 Формулировка задачи оптимизации

Данную задачу можно представить как задачу оптимизации. Основные параметры модели:

- W, H — ширина и высота входного изображения (пиксели);
- n — количество слоёв нейронной сети;
- k — количество якорных рамок;

- mAP_{raw} — нижняя граница mAP для исходного набора параметров (W, H, k) ;
- Δ_{raw} — допустимое снижение точности;
- Δ — желаемый прирост точности (в процентах);
- FPS_{min} — минимальное значение FPS для задачи;
- FPS' — нормализованное FPS в диапазоне $[0, 1]$, $FPS' = 1 - \frac{FPS}{\infty}$;
- $\alpha_1, 1 - \alpha_1$ — коэффициенты значимости метрик.

Критерий оптимизации при заданном наборе параметров (W, H, n, k) имеет вид:

$$|1 - (\alpha_1 \cdot mAP + (1 - \alpha_1) \cdot FPS')| \rightarrow \min, \quad (1)$$

$$\alpha_1, mAP, FPS' \in [0, 1].$$

Ограничения для задачи:

$$n < n_{max}, \quad (2)$$

$$mAP_{raw} = mAP_{n_0} - \Delta_{raw}, \quad (3)$$

$$mAP(W, H, n, k) \geq mAP_{raw} + \Delta, \quad (4)$$

$$FPS(W, H, n, k) \geq FPS_{min}. \quad (5)$$

1.4 Алгоритм повышения точности сети

В работе [1] предложен итеративный алгоритм подбора архитектурных и входных параметров модели нейросетей, направленный на достижение компромисса между точностью детекции объектов и производительностью системы.

Изменение архитектуры

1. Зафиксировать начальное количество слоёв: n_0 .
2. Уменьшить количество слоёв до $n < n_0$ 2 методом модифицированного двоичного поиска:
 - (a) Установить диапазон поиска: $n \in [n_{min}; n_{max}]$, где $n_{min} = 5$, $n_{max} = n_0 - 1$.
 - (b) Вычислить среднее значение: $n_{mid} = (n_{min} + n_{max})/2$.
 - (c) Измерить метрики: $mAP(n_{mid})$, $FPS(n_{mid})$.
 - (d) Если $FPS(n_{mid}) \geq FPS_{min}$ 5 и $mAP(n_{mid})3 \geq mAP_{raw}$, уменьшаем глубину модели: $n_{max} = n_{mid}$.
 - (e) Иначе $n = n_{max}$ (выбираем последнее удовлетворяющее значение).

Изменение входных данных

- Размер входного изображения $W_n \times H_n$ изменяется кратно 32 (например, уменьшение: $640 \rightarrow 416 \rightarrow 320$, увеличение: $416 \rightarrow 512 \rightarrow 640$).

- Для повышения точности $mAP \uparrow$ и снижения производительности $FPS \downarrow$ увеличивают W, H .
- Для снижения точности $mAP \downarrow$ и повышения производительности $FPS \uparrow$ уменьшают W, H .

Пример изменения размера входного изображения и соответствующей точности:

Размер $W \times H$	mAP
416×416	0.37
608×608	0.58

Изменение количества якорных рамок

Нахождение оптимального количества якорных рамок включает несколько этапов:

1. **Масштабирование рамок:** Каждая рамка исходного размера (w_t, h_t) масштабируется под новое разрешение входного изображения (W_i, H_i) :

$$(w_r, h_r) = \left(\frac{W_n}{W_i} \cdot w_t, \frac{H_n}{H_i} \cdot h_t \right) \quad (6)$$

где (W_n, H_n) — исходное разрешение сети.

2. **Кластеризация k -средних:** Провести кластеризацию (w_r, h_r) для k центров:

$$(w_c, h_c) = k\text{-means}(w_r, h_r) \quad (7)$$

где (w_c, h_c) — усреднённые размеры объектов в кластерах.

3. **Определение оптимального числа кластеров k :** Экспериментируют со значением k от 3 до 15, вычисляя силуэт средних коэффициентов:

$$\bar{S}(k) = \frac{1}{m} \sum_{i=1}^m S(i), \quad (8)$$

$$S_k = \frac{b - a}{\max(a, b)} \quad 8, 9 \quad (9)$$

где m — число элементов в кластеризации, a — среднее внутрикластерное расстояние, b — ближайшее межкластерное расстояние. Максимум $\bar{S}(k)$ определяет оптимальное количество кластеров k .

Нормализация якорей

Для корректной работы сети размеры якорных рамок нормализуются относительно шага карты признаков:

$$(w_a, h_a) = \left(\frac{w_c}{feat_{st}}, \frac{h_c}{feat_{st}} \right) \quad (10)$$

где w_a, h_a — размеры якорей в масштабе feature map, с которым работает последний слой модели, а $feat_{st} = 2^n$ — шаг карты признаков, где сеть содержит n слоёв max pooling. Данный подход позволяет адаптировать размеры якорных рамок к распределению объектов в обучающем наборе, повышая точность локализации (IoU) без увеличения вычислительной нагрузки.

Оценка результатов

После настройки архитектуры, размеров входного изображения и якорей проводится измерение основных метрик модели: *mAP*, *Precision*, *Recall*, *IoU* и *FPS*. Эти показатели позволяют оценить баланс между точностью распознавания и производительностью модели, а также подтвердить эффективность проведённой оптимизации.

Порядок выполнения алгоритма

Алгоритм повышения точности сети выполняется в следующем порядке:

1. Нахождение значения n , удовлетворяющего условиям задачи.
2. С найденным n осуществляется поиск подходящего размера входного изображения W , H .
3. С изменёнными параметрами W , H , n производится вычисление оптимального количества якорных рамок k .

1.5 Итоги анализа

Представленный подход позволяет адаптировать архитектурные и входные параметры модели нейросетей под доступные вычислительные ресурсы, обеспечивая:

- **Сопоставимые показатели:** достижение значений метрик качества, сопоставимых с исходной моделью, при оптимизации архитектуры.

- **Эффективность ресурсов:** значительное снижение вычислительной сложности модели, что важно для систем компьютерного зрения на мобильных и малопроизводительных устройствах.

Пример результатов работы алгоритма

Модель	n	k	$W \times H$	Recall (%)	Precision (%)	IoU (%)	mAP (%)	FPS
Базовая	24	3	416×416	80	78	75	72	5–20
Оптим.	9	9	608×608	85	84	82	82.21	50–100

[1]

Комментарий к результатам:

- Число слоёв n уменьшено с 24 до 9, что существенно снизило вычислительную сложность модели.
- Метрики точности (Recall, Precision, IoU, mAP) выросли на 5–10% по сравнению с исходной моделью.
- FPS увеличился в 5–10 раз, что демонстрирует высокую эффективность оптимизации для мобильных и малопроизводительных устройств.

Перспективы

Дальнейшие перспективы развития задачи заключаются в возможном применении описанного алгоритма в рамках следующих семестров. Алгоритм подходит для решения проблем с производительностью при использовании технологий компьютерного зрения и моделей распознавания объектов на малопроизво-

дительных и мобильных устройствах, например, таких как беспилотный летательный аппарат, производящий патрулирование и анализ дефектов дорожного покрытия в городе с помощью встроенной камеры.

2 Система видеоаналитики дефектов дорожного покрытия

Данный раздел посвящён описанию проекта системы автоматического обнаружения и классификации дефектов дорожного покрытия на основе видеоданных. Основная цель проекта заключается в обеспечении автоматизированного мониторинга состояния дорог с целью оперативного выявления повреждений, формирования аналитических отчётов и поддержки принятия решений по ремонту и обслуживанию инфраструктуры.

2.1 Цели и задачи системы

Основные цели системы:

- автоматическое обнаружение и классификация дефектов дорожного покрытия;
- формирование аналитической информации о состоянии дорожного полотна;
- обеспечение возможности генерации отчётов в формате ГОСТ и ОДМ.

В рамках этих целей система решает следующие задачи:

1. Обработка видеоданных, представленных в виде файлов формата `.avi`, полученных с мобильной лаборатории.
2. Предобработка и нормализация видео для обеспечения стабильной работы алгоритмов компьютерного зрения.

3. Детекция и классификация дефектов дорожного покрытия с использованием обученных моделей нейросетей.
4. Визуализация результатов обработки видео с наложением меток дефектов и их классификацией.
5. Формирование аналитических отчётов и статистики по состоянию дорожного покрытия.

2.2 Источники данных

Для работы системы используются следующие источники данных:

- Видеоданные, получаемые с трёх высокоразрешающих цифровых камер, установленных на мобильной лаборатории.
- Дополнительные сенсорные данные: акселерометры, лазерно-оптический сканер и GPS-информация.
- Метаданные о положении фургона, километраже, координатах и направлении движения.

2.3 Методы и подходы

Для детекции и классификации дефектов применяются методы компьютерного зрения, основанные на моделях нейросетей. Современные методы распознавания дефектов дорожного покрытия включают подходы с сегментацией пикселей, такие как Mask R-CNN, позволяющие выделять трещины непосредственно на поверхности полотна [4]. Основные подходы включают:

- Сегментацию и детекцию объектов на кадрах видеопотока.
- Использование предварительно обученных моделей с последующей адаптацией под конкретные условия дорожного покрытия.
- Оптимизацию моделей для работы с учётом ограниченных вычислительных ресурсов мобильной лаборатории.

Сравнительное исследование показало, что сверточные нейронные сети различной архитектуры могут обеспечивать высокую точность обнаружения трещин в реальных дорожных условиях, что подтверждается в ряде работ [5].

Связь с магистерской работой

Реализованный проект системы видеоаналитики напрямую связан с темой магистерской диссертации, так как использует методы компьютерного зрения и оптимизированные модели нейросетей для анализа видеопотока в производственных системах. Опыт разработки и адаптации системы к реальным условиям эксплуатации формирует практическую основу для дальнейших исследований и внедрения алгоритмов автоматизированного визуального контроля.

Заключение

В рамках выполнения промежуточного этапа магистерской диссертации была проведена исследовательская работа, направленная на обоснование методов оптимизации моделей нейросетей и разработки системы видеоаналитики для обнаружения дефектов дорожного покрытия. Поставленная цель была достигнута путем решения ряда задач.

В первой части работы проведён анализ научной статьи, посвящённой оптимизации моделей нейросетей для задач компьютерного зрения. Были рассмотрены подходы к снижению вычислительной сложности моделей при сохранении высокой точности распознавания, проанализированы параметры и метрики модели (количество слоёв, размер входного изображения, количество якорей), а также предложен алгоритм подбора оптимальных параметров. Итогом анализа стало понимание компромисса между точностью и производительностью модели и формирование рекомендаций по применению описанных методов в практических системах видеоаналитики.

Во второй части работы рассмотрен проект системы видеоаналитики дефектов дорожного покрытия. Описаны цели и задачи системы, источники данных (видео с мобильной лаборатории и дополнительные сенсоры), методы и подходы к детекции и классификации дефектов с использованием обученных моделей нейросетей. Показана связь проекта с темой магистерской работы, а также определена роль оптимизации моделей для работы с реальными видеоданными и ограниченными вычислительными

ресурсами.

Таким образом, на текущем этапе достигнуты следующие результаты:

- систематизированы знания о методах оптимизации моделей нейросетей для задач компьютерного зрения;
- проанализированы параметры и метрики моделей, влияющие на баланс между точностью и производительностью;
- сформировано представление о практическом применении этих методов в проекте по видеоаналитике дорожной инфраструктуры;
- определены направления дальнейшей работы:
 - продолжение теоретического анализа современных методов компьютерного зрения и оптимизации для повышения производительности моделей;
 - разметка датасета видеоданных дорожного покрытия;
 - обучение и тестирование моделей нейросетей для распознавания и классификации дефектов;
 - интеграция моделей в прототип системы видеоаналитики и оценка её точности и производительности;

Промежуточный этап работы позволил систематизировать теоретические знания и практический опыт, а также определить основные направления дальнейшего исследования в области компьютерного зрения и оптимизации моделей нейросетей в рамках магистерской работы.

Список литературы

1. Tarek Teama, Hongbin Ma, Ali Maher, and Mohamed A. Kassab. 2019. Real Time Object Detection Based on Deep Neural Network. In Intelligent Robotics and Applications: 12th International Conference, ICIRA 2019, Shenyang, China, August 8–11, 2019, Proceedings, Part IV. Springer-Verlag, Berlin, Heidelberg, 493–504.
2. Redmon, J. You Only Look Once: Unified, Real-Time Object Detection / J. Redmon, S. Divvala, R. Girshick, A. Farhadi. - ВАШИНГТОН: IEEE Conference on Computer Vision and Pattern Recognition CVPR, 2016.- С. 10.
3. SSD: Single Shot MultiBox Detector, Computer Vision – ECCV 2016 / W. Liu, D. Anguelov, D. Erhan [и др.]. - Амстердам: Springer International Publishing AG, 2016.- с. 21-37. wa
4. Wang, P. Research on Automatic Pavement Crack Recognition Based on the Mask R-CNN Model / P. Wang, C. Wang, H. Liu, M. Liang, W. Zheng, H. Wang, S. Zhu, G. Zhong, S. Liu // Coatings. – 2023. – Vol. 13, No. 2. – Article 430. – DOI: 10.3390/coatings13020430.
5. Tapamo, H. Convolutional Neural Networks for Crack Detection on Flexible Road Pavements / H. Tapamo, A. Bosman, J. Maina, E. Horak. – arXiv preprint arXiv:2304.02933, 2023. – DOI: 10.48550/arXiv.2304.02933.