

1 - Нейронные сети: что это, и как они работают

В основе современных систем автоматизированного визуального контроля лежат искусственные нейронные сети. В контексте распознавания объектов на основе методов машинного зрения нейронная сеть представляет собой сложную вычислительную архитектуру, математически имитирующую процессы распознавания образов и анализа пространственных признаков на изображении.

Чтобы понять принцип работы такой системы, необходимо провести границу между классическим программированием и парадигмой машинного обучения. В традиционном алгоритмическом подходе разработчик вручную формирует набор жестких правил и инструкций. Например, описывает строгие геометрические или цветовые параметры, при совпадении которых программное обеспечение должно классифицировать объект на фото как дефект.

Подобный подход оказывается неэффективным при работе с реальными визуальными данными. Объекты реального мира подвержены влиянию огромного количества нестабильных факторов: изменению освещенности, появлению теней, смене погодных условий и ракурсов съемки. Охватить все возможные комбинации этих факторов и описать их через строгие логические операторы кода физически невозможно - классический алгоритм в таких условиях будет работать неправильно.

Машинное обучение решает эту проблему принципиально иным путем: модель не содержит заранее написанных правил распознавания. Вместо программирования условий, алгоритму предоставляется массив «правильных ответов» — набор размеченных человеком данных. Анализируя этот массив, система с помощью высшей математики самостоятельно выявляет скрытые закономерности и общие признаки целевых объектов.

С технической точки зрения обученная нейронная сеть не содержит внутри себя логических ветвлений или привычных строк кода. Она представляет собой обширную матрицу настраиваемых числовых коэффициентов, которые в машинном обучении называются «весами» (weights) модели. Изначально эти значения случайны, однако в процессе математической оптимизации (обучения) они корректируются. Настраиваясь, различные группы этих коэффициентов начинают функционировать как высокоточные математические фильтры: одни реагируют на резкие перепады контрастности, выявляя границы объектов, другие фокусируются на специфической геометрической деформации или изменениях текстуры покрытия. Таким образом, вместо исполнения жесткого алгоритма, система опирается на сложный многоуровневый фильтр, способный с высокой

долей вероятности классифицировать дефекты даже на тех изображениях, которые она ранее никогда не обрабатывала.

2 - Данные вместо кода

В машинном обучении фокус смещается с написания логики на работу с информацией. В традиционной разработке создание алгоритма может занять длительное время написания кода, а в компьютерном зрении программный скрипт, запускающий процесс обучения, может сводиться к небольшому конфигурационному файлу. Техническая сложность ценность проекта заключаются в формировании качественного набора данных (датасета).

Поскольку модель не опирается на заранее заданные геометрические или цветовые правила, ей требуется больший демонстрирующий объем примеров для самостоятельного вывода математических закономерностей. Создание таких примеров реализуется через процесс разметки (аннотирования) визуальных данных.

Используя программное обеспечение, специалист по разметке вручную отмечает каждый целевой объект на изображении. Для классических задач детекции повреждение выделяется строгими прямоугольными контурами (bounding boxes). Каждому выделенному контуру присваивается точный идентификатор целевого класса - например, выбоина, гребенка или просадка.

Сформированный массив исходных изображений, неразрывно связанный с файлами координат и классов, образует итоговую выборку. Эти данные выступают в роли абсолютной истины для алгоритма в процессе обучения. Модель постоянно сравнивает свои текущие математические предсказания с этой разметкой, чтобы скорректировать внутренние весовые коэффициенты при обнаружении ошибки. Этот процесс называется валидацией.

3 - Трансферное обучение

Обучение нейронной сети с нуля требует колоссальных вычислительных мощностей и времени. Пустой модели пришлось бы осваивать базовые принципы компьютерного зрения: распознавание границ, теней и текстур, на что ушли бы недели вычислений и сотни тысяч исходных фотографий.

Для радикальной оптимизации процесса применяется метод трансферного обучения (Transfer Learning). В качестве базы используется сложная архитектура (в данном проекте и на данном этапе - предобученные модели RTMDet), уже прошедшая этап базового обучения на миллионах изображений общего назначения. Эта модель изначально

содержит в своих математических весах фундаментальное понимание геометрии, перспективы и форм. Она уже умеет выделять объекты на сложном фоне.

Этот процесс обучения фактически является дообучением (Fine-tuning) - узкой специализацией. Мы предоставляем опытной модели специализированный датасет с размеченными дефектами покрытия, чтобы она перенастроила свои внутренние фильтры под новую задачу. Нейросети больше не нужно учиться распознавать простейшие детали с нуля - она лишь адаптирует накопленный визуальный опыт для отметки дорожных дефектов. Это сильно сокращает цикл обучения и гарантирует высокую точность даже на ограниченных объемах размеченных данных.

4 - Конфигурация обучения: гиперпараметры

Процесс адаптации внутренних фильтров нейронной сети контролируется через набор стартовых настроек, называемых гиперпараметрами. В отличие от внутренних весов, которые модель настраивает сама, гиперпараметры задаются человеком до начала вычислений и выступают в роли способа управления всем процессом обучения.

Рассмотрим ключевые параметры, определяющие качество и стабильность обучения:

Эпохи (Epochs)

Эпохи определяют количество полных циклов обработки всего тренировочного массива данных. Однократного прохождения датасета алгоритму недостаточно для выявления сложных закономерностей, однако чрезмерное количество эпох приводит к «переобучению» (overfitting) - состоянию, когда модель начинает банально заучивать конкретные тренировочные фотографии вместо понимания общих принципов. Оптимальное число эпох позволяет системе извлечь максимум полезного опыта, сохраняя при этом способность распознавать дефекты на ранее неопознанных кадрах.

Размер батча (Batch Size)

Размер батча указывает, какое количество изображений нейросеть анализирует одновременно перед выполнением математической работы над ошибками и обновлением своих весов. Чем больше батч, тем точнее алгоритм усредняет ошибку и определяет вектор для корректировки, однако этот параметр жестко ограничен аппаратными ресурсами (объемом видеопамяти серверов). Правильно подобранный размер батча обеспечивает стабильность процесса обучения и защищает его от резких непредсказуемых скачков.

Скорость обучения (Learning Rate)

Скорость обучения - это коэффициент, определяющий величину математического шага при корректировке весов модели. Если задать слишком агрессивный шаг, алгоритм начнет «перепрыгивать» оптимальные решения, теряя полезный опыт и нестабильно меняя свои предсказания. Если шаг чрезмерно мал, процесс тренировки неоправданно затянется, а модель рискует застрять в локальных математических тупиках, так и не достигнув требуемой точности детекции.

Оптимизаторы (Optimizers)

Оптимизатор (например, SGD, Adam или AdamW) представляет собой математический алгоритм, который непосредственно управляет процессом обновления весов на основе полученных ошибок. Современные оптимизаторы функционируют как интеллектуальные навигаторы: они способны динамически адаптировать скорость обучения для каждого отдельного параметра модели в реальном времени. Это позволяет вычислительному процессу плавно замедляться при приближении к идеальному решению и преодолевать сложные участки данных.

Регуляризация (Weight Decay)

Коэффициент регуляризации выступает в роли встроенного механизма штрафов за чрезмерную сложность модели. Он искусственно ограничивает рост числовых значений внутри нейросети, не позволяя ей фокусироваться на ложных, специфических артефактах конкретной фотографии (например, уникальном блике света). Этот параметр принуждает алгоритм анализировать комплексные, обобщенные признаки дефекта, что критически важно для сохранения универсальности системы в реальных, полевых условиях эксплуатации.

5 - Оценка качества модели: Объективные метрики

Завершение процесса вычисления и обновления весов не означает, что система готова к эксплуатации. Обученной нейросети необходимо пройти тест на валидационной выборке - массиве контрольных фотографий, которые алгоритм никогда ранее не обрабатывал и не видел на этапе обучения. В машинном обучении качество работы оценивается не визуально-субъективным восприятием разработчика, а с помощью строгих математических метрик.

Рассмотрим три главных показателя, которые формируют итоговую оценку алгоритма:

Уверенность предсказания (Confidence Score)

Когда нейросеть обнаруживает потенциальный объект, она сопровождает свой вывод внутренним коэффициентом уверенности - значением в диапазоне от 0% до 100% (в практике значениями от 0 до 1). Этот показатель отражает степень активации внутренних фильтров модели при анализе конкретной группы пикселей. Параметр Confidence служит главным инструментом фильтрации визуального шума в готовом приложении. Устанавливая программный порог (например, 50%), отсекаются все сомнительные срабатывания алгоритма, оставляя только те дефекты, в наличии которых модель убеждена.

Пространственная точность - IoU (Intersection over Union)

Метрика IoU (Пересечение поверх объединения) оценивает физическую точность обнаружения объекта на кадре. Для ее расчета система накладывает друг на друга две рамки или силуэта: истинную, которую изначально была получена на этапе разметки, и предсказанную, которую вычислила нейросеть. IoU вычисляет отношение площади пересечения этих двух контуров к их суммарной площади. Значение 1.0 (или 100%) означает идеальное геометрическое совпадение пиксель в пиксель. В стандартах детекция обычно засчитывается как успешная, если показатель IoU превышает 0.5 (то есть контуры перекрываются более чем на половину).

Комплексная эффективность - mAP (Mean Average Precision)

Показатель mAP (Усредненная средняя точность), главная интегральная метрика, собирает данные по всем классам дефектов и оценивает баланс между двумя факторами:

1. **Точностью (Precision):** Эта метрика вычисляет, какая доля из всех нарисованных нейросетью контуров действительно содержит дефект - доля истинных дефектов среди абсолютно **всех** объектов, которые алгоритм классифицировал как повреждения. Если у модели низкая точность, она будет принимать за выбоины фон, другие дефекты и случайные объекты.
2. **Полнотой (Recall):** Эта метрика вычисляет долю найденных нейросетью дефектов от общего числа фактически существующих на полотне повреждений. Низкая полнота означает наличие критических пропусков реальных разрушений и игнорирование сложных, нестандартных или плохо освещенных трещин.

Высокий уровень mAP свидетельствует о том, что вычислительная система достигла оптимального равновесия: она успешно обнаруживает подавляющее большинство реальных дефектов дорожного полотна, минимизируя при этом количество ложных срабатываний на визуальные артефакты.

6 - Итоги

Результатом завершеного процесса машинного обучения является файл весовых коэффициентов - математическая модель, содержащая характеристики визуальных признаков целевых дефектов.

На этапе практической эксплуатации (инференса) алгоритму больше не требуется доступ к исходным обучающим датасетам. Полученная модель интегрируется в конечное программное обеспечение в виде независимого вычислительного модуля.

Это позволяет развернуть автономную систему, обеспечивающую автоматизированный потоковый анализ визуальных данных, позволяя обнаруживать повреждения дорожного покрытия.