

1 - Нейронные сети: что это, и как они работают

В основе современных систем визуального контроля лежат искусственные нейронные сети - вычислительная архитектура, математически имитирующая процессы распознавания пространственных признаков на изображении

Однако для реальных данных это неэффективно: охватить строгими логическими операторами кода все нестабильные факторы (изменение освещенности, тени, погоду) физически невозможно.

Чтобы понять их работу, необходимо отделить машинное обучение от классического программирования. В традиционном подходе разработчик вручную формирует набор жестких правил и инструкций. Например, описывает строгие геометрические или цветовые параметры, при совпадении которых программное обеспечение должно классифицировать объект на фото как дефект.

Однако для реальных данных это неэффективно: охватить все возможные комбинации этих факторов, такие как изменение освещенности, появление теней, погодные условия, ракурс съемки, физически невозможно и описать их через строгие логические операторы кода.

Машинное обучение решает проблему иначе: вместо программирования условий алгоритму предоставляется массив «правильных ответов» — набор размеченных человеком данных. Анализируя их, система самостоятельно выявляет общие закономерности целевых объектов.

Машинное обучение решает эту проблему иначе: вместо программирования условий алгоритму предоставляется массив правильных ответов - набор размеченных человеком данных. Анализируя их, система самостоятельно выявляет общие закономерности целевых объектов.

С технической точки зрения обученная нейронная сеть не содержит логических ветвлений или привычных строк кода. Она представляет собой матрицу числовых коэффициентов - «весов» (weights) модели, которые корректируются в процессе обучения. Изначально эти значения случайны, однако в процессе обучения они корректируются. Технически это реализуется через архитектуру сверточных нейронных сетей (CNN), которые работают за счет последовательно скользящего по пикселям изображения окна.

При обучении группы коэффициентов начинают функционировать как фильтры, реагируя на перепады контрастности, выявляя границы объектов, фокусируются на геометрической деформации или изменениях текстуры покрытия. Таким образом, вместо исполнения

жесткого алгоритма, система опирается на сложный многоуровневый фильтр, способный классифицировать дефекты даже на тех изображениях, которые она ранее не обрабатывала.

2 - Данные вместо кода

В машинном обучении фокус смещается с написания логики на работу с информацией. В отличие от традиционной разработки, где написание кода занимает длительное время, запуск обучения в компьютерном зрении часто сводится к выполнению скрипта с небольшим конфигурационным файлом (документом, где заданы стартовые настройки обучения нейронной сети). Техническая сложность и ценность проекта заключаются в формировании качественного набора данных (датасета).

Поскольку модель не опирается на заранее заданные геометрические правила, ей требуется большой объем примеров для самостоятельного вывода математических закономерностей. Это реализуется через процесс разметки (аннотирования) визуальных данных. Вручную отмечается каждый целевой объект на изображении строгими прямоугольными рамками (bounding boxes) или контурами, присваивая им точный идентификатор класса - выбоина, гребенка и др.

Сформированный массив изображений, связанный с файлами координат и классов, образует итоговую выборку. Эти данные выступают в роли абсолютной истины для алгоритма в процессе обучения. Модель постоянно сравнивает свои текущие математические предсказания с разметкой, чтобы скорректировать внутренние весовые коэффициенты при обнаружении ошибки.

3 - Трансферное обучение

Обучение нейронной сети с нуля требует больших мощностей и времени: пустой модели пришлось бы осваивать базовые принципы компьютерного зрения, такие как границы, тени, текстуры. Для радикальной оптимизации применяется метод трансферного обучения (Transfer Learning). В качестве базы используется сложная архитектура (в данном проекте - предобученные модели RTMDet-Ins), уже прошедшая базовое обучение на миллионах изображений общего назначения.

Эта модель изначально содержит в весах понимание геометрии, перспективы и форм, умея выделять объекты на сложном фоне. Дальнейший процесс обучения фактически является дообучением (Fine-tuning) - узкой специализацией. Мы предоставляем опытной модели специализированный датасет с размеченными дефектами покрытия, чтобы она

перенастроила внутренние фильтры. Нейросети больше не нужно учиться с нуля - она адаптирует накопленный визуальный опыт, что сокращает цикл обучения и гарантирует высокую точность даже на ограниченных объемах данных.

4 - Конфигурация обучения: гиперпараметры

Процесс адаптации внутренних фильтров контролируется через набор стартовых настроек - гиперпараметров. В отличие от внутренних весов, настраиваемых самой моделью, гиперпараметры задаются человеком до начала вычислений для управления всем процессом обучения.

Ключевые параметры, определяющие качество:

Эпохи (Epochs)

- определяют количество полных циклов обработки тренировочного массива данных. Однократного прохождения датасета недостаточно, но избыток ведет к переобучению (overfitting) - заучиванию конкретных фотографий вместо понимания общих принципов. Оптимальное число позволяет извлечь опыт, сохраняя способность распознавать дефекты на новых кадрах

Размер партии (Batch Size)

- указывает количество изображений, анализируемых одновременно перед математической работой над ошибками и обновлением весов. Большой размер точнее усредняет ошибку, но жестко ограничен объемом видеопамяти. Правильный размер обеспечивает стабильность обучения без резких скачков.

Скорость обучения (Learning Rate)

- определяет величину математического шага при корректировке весов модели. При агрессивном шаге алгоритм начнет переступать оптимальные решения, а при слишком малом - затян Timer обучения, рискуя застрять в локальных тупиках.

Оптимизаторы (Optimizers)

- алгоритмы (например, SGD, Adam или AdamW) управляют процессом обновления весов на основе полученных ошибок. Они динамически адаптируют скорость

обучения для каждого параметра, плавно замедляя вычисления при приближении к идеальному решению.

Регуляризация (Weight Decay)

- выступает механизмом штрафов за чрезмерную сложность, ограничивая рост числовых значений внутри нейросети. Она не позволяет фокусироваться на специфических артефактах (например, бликах света), принуждая анализировать обобщенные признаки дефекта для реальных условий эксплуатации.

5 - Оценка качества модели: Объективные метрики

Завершение обновления весов не означает готовность системы к эксплуатации. Обученной нейросети необходимо пройти тест на валидационной выборке - массиве контрольных фотографий, которые алгоритм не обрабатывал на этапе обучения. В машинном обучении качество работы оценивается не визуально-субъективным восприятием разработчика, а с помощью строгих математических метрик.

Рассмотрим три главных показателя:

Уверенность предсказания (Confidence Score)

Когда нейросеть обнаруживает объект, она сопровождает вывод внутренним коэффициентом уверенности от 0 до 100% (от 0 до 1). Этот показатель отражает степень активации внутренних фильтров модели. Параметр служит главным инструментом фильтрации визуального шума: устанавливая программный порог (например, 50%), отсекаются сомнительные срабатывания, оставляя только дефекты, в наличии которых модель убеждена

Пространственная точность - IoU (Intersection over Union)

Метрика IoU (Пересечение поверх объединения) оценивает физическую точность обнаружения объекта на кадре. Система накладывает друг на друга две рамки (истинную из разметки и предсказанную нейросетью), вычисляя отношение площади пересечения контуров к их суммарной площади. Значение 1.0 (или 100%) означает идеальное совпадение. В стандартах детекция засчитывается как успешная, если показатель IoU превышает 0.5 (пересечение более половины).

Комплексная эффективность - mAP (Mean Average Precision)

Показатель mAP (Усредненная средняя точность), главная интегральная метрика, собирает данные по всем классам дефектов и оценивает баланс между двумя факторами:

1. **Точностью (Precision):** Доля истинных дефектов среди абсолютно всех объектов, классифицированных алгоритмом как повреждения. При низкой точности модель принимает за выбоины фон и случайные объекты.
2. **Полнотой (Recall):** Доля найденных дефектов от общего числа фактически существующих на полотне повреждений. Низкая полнота означает критические пропуски реальных разрушений и игнорирование сложных трещин.

Высокий уровень mAP свидетельствует о достижении оптимального равновесия: система успешно обнаруживает подавляющее большинство реальных дефектов дорожного полотна, минимизируя ложные срабатывания на визуальные артефакты.

6 - Итоги

Результатом завершеного процесса машинного обучения является файл весовых коэффициентов - математическая модель, содержащая характеристики визуальных признаков целевых дефектов.

На этапе практической эксплуатации (инференса) алгоритму больше не требуется доступ к исходным обучающим датасетам. Полученная модель интегрируется в систему в виде независимого вычислительного модуля.

Это позволяет развернуть автономную систему, обеспечивающую автоматизированный потоковый анализ визуальных данных для обнаружения повреждений дорожного покрытия.